# Universidad Tecnológica de El Salvador

## FACULTAD DE INGENIERÍA Y CIENCIAS APLIACADAS

## ESCUELA DE INFORMÁTICA

## CICLO 01-2026

**ASIGNATURA: Técnicas de Producción Industrial de Software**

**SECCIÓN: 01**

**DOCENTE: ING. JORGE MACHADO**

**NOMBRE DE LA ACTIVIDAD:**

**Caso práctico individual con análisis en Python.**

**Presentado por:**


| **Alumno** | **Carnet** |
|---|---|
| David Enrique Chávez Lazo | 25-3453-2021 |


**Fecha de entrega:** 12 de mayo de 2026.

**INTRODUCCIÓN** ..... **3**

**OBJETIVOS** ..... **4**

Objetivo general: ..... 4
Objetivos específicos: ..... 4

**DESARROLLO DEL TRABAJO** ..... **5**

Actividad 1. Preparación e inspección inicial del dataset ..... 5
Actividad 2. Análisis de relación entre variables. ..... 5
Actividad 3. Visualización de resultados. ..... 5
Actividad 4. Análisis de agrupación de ocupaciones ..... 6
Actividad 5. Interpretación orientada a producción industrial de software. ..... 7

**CONCLUSIÓN** ..... **10**

**ANEXOS** ..... **11**

## Introducción

El análisis de datos nos muestra un panorama claro sobre los objetivos, metas, misión y visión de una organización, con ello podemos determinar el rumbo que lleva todos los objetivos planteados, si hay perdidas o ganancias, si hay información fiable. Podremos tomar las decisiones adecuadas para tratar lo que nos muestran los datos; es debido a ello que en este trabajo se presenta una manera de minar datos, por lo cual, y debido a ello se presenta este análisis de un data set.

Dicho análisis que corresponde al papel de una organización dedicada al desarrollo de software a escala industrial, las decisiones sobre talento, formación, roles, especialización y mejora de procesos deben apoyarse cada vez más en datos. Para este caso práctico, vamos a trabajar con un conjunto de datos denominado Prestige_modificado.csv. El archivo contiene información sobre ocupaciones, educación promedio, ingresos, porcentaje de mujeres, prestigio ocupacional, código censal y tipo de ocupación. Con ello buscamos demostrar la efectiva aplicación de técnicas de análisis de datos y demostrar el fuerte desempeño y necesidad de siempre contar con un área especializado en tratamiento de datos para cualquier empresa.

## Objetivos

**Objetivo general:**

- Demostrar mediante técnicas de análisis de datos las fortalezas en la formación de talento para IT.

**Objetivos específicos:**

- Identificar las fortalezas de los encuestados para el prestigio de diferentes ocupaciones.
- Analizar variables socioeconómicas que ayuden a comprender mejor las relaciones entre estudios, ingresos y participaciones de mujeres.
- Calcular los datos de manera consistente y estructurado para su demostración de resultados.

## Desarrollo del Trabajo

**Actividad 1. Preparación e inspección inicial del dataset.**

El dataset contiene 102 registros y 7 columnas. No presenta valores nulos ni registros duplicados, por lo que no requiere eliminación de filas. Los tipos de datos son correctos: variables numéricas continuas (**education, income, women, prestige**) y enteros para **census y type_num**. El dataset está listo para el análisis sin necesidad de limpieza adicional. Se observa que la variable income tiene alta dispersión (std ≈ 4,245), lo que puede influir en los modelos de agrupación, por eso se aplicará escalamiento antes de K-Means.

**Actividad 2. Análisis de relación entre variables.**

Las variables con relación positiva más fuerte respecto a prestige son education ($r \approx 0.85$) e income ($r \approx 0.71$). Esto es coherente desde el punto de vista laboral: las ocupaciones que requieren mayor nivel educativo y generan mejores ingresos tienden a ser socialmente más valoradas. La variable women muestra una correlación negativa o muy débil con prestige, lo que refleja una brecha histórica donde las ocupaciones con mayor participación femenina han tendido a recibir menor reconocimiento social. Type_num también presenta correlación positiva moderada con prestige.

Algo que se debe de tomar en cuenta es que correlación no implica causalidad. El hecho de que education y prestige estén correlacionadas no significa que aumentar la educación cause directamente mayor prestigio; pueden existir variables intermedias no capturadas en el dataset.

**Actividad 3. Visualización de resultados.**

Se observa una relación positiva clara entre el nivel educativo y el prestigio ocupacional. A medida que aumenta el promedio de años de educación asociados a una ocupación, su valoración social también tiende a ser mayor. La dispersión de puntos sugiere una tendencia lineal fuerte, coherente con la correlación de $r \approx 0.85$ calculada anteriormente.

La relación entre ingreso y prestigio es positiva, pero con mayor dispersión que la de educación. Existen ocupaciones con ingresos altos y prestigio moderado (como algunos oficios técnicos bien remunerados), y otras con ingresos bajos pero mayor reconocimiento social. Esto indica que el ingreso influye en el prestigio, pero no lo determina completamente.

Las ocupaciones de tipo Profesional/Técnica/Gerencial concentran los niveles más altos de prestigio, tanto en promedio como en mediana. Las ocupaciones White Collar presentan un nivel intermedio, mientras que las Blue Collar registran los valores más bajos. Este patrón es esperado y coherente con la realidad laboral: los roles que combinan mayor formación, responsabilidad y especialización técnica o gerencial suelen recibir mayor valoración social.

**Actividad 4. Análisis de agrupación de ocupaciones**

Modelo K=4: Genera cuatro grupos bien diferenciados. El clúster con mayor prestigio promedio agrupa ocupaciones profesionales con alta educación e ingresos. El clúster de menor prestigio concentra ocupaciones manuales o de servicios básicos. Los clústeres intermedios representan perfiles técnicos y administrativos.

Modelo K=5: Al agregar un quinto grupo, el modelo subdivide uno de los clústeres intermedios de K=4, separando ocupaciones técnicas de ocupaciones

administrativas con características distintas. Esto permite mayor detalle, pero también puede dificultar la interpretación si los grupos no son suficientemente distintos entre sí.

Justificación de elección: Se considera que el modelo con **K=4** ofrece la mejor interpretación para este caso, porque los cuatro grupos se alinean naturalmente con los tipos de ocupación del dataset (sin tipo, profesional/técnico/gerencial, blue collar, white collar). El modelo K=5 subdivide un grupo que en la práctica tiene comportamiento homogéneo, añadiendo complejidad sin una ganancia interpretativa clara.

**Actividad 5. Interpretación orientada a producción industrial de software.**

**¿Qué variables tienen mayor relación con el prestigio de una ocupación?**

Los resultados del análisis de correlación muestran que **Education** es la variable con mayor relación con Prestige ($r \approx 0.85$), seguida de **Income** ($r \approx 0.71$). Esto indica que las ocupaciones más valoradas socialmente son aquellas que exigen mayor formación y generan mejores ingresos. La variable **Women** presenta una correlación negativa débil, lo que puede reflejar brechas históricas de valoración, no una relación causal.

**¿Cómo puede una empresa de software usar este análisis para valorar roles?**

InnovaSoft Analytics puede aplicar este tipo de análisis para:

- **Valoración de roles técnicos vs. gerenciales:** Identificar qué perfiles (desarrolladores, arquitectos, líderes de proyecto, analistas de datos) se asocian a mayores niveles de formación e ingreso, y usar esa información para estructurar escalas salariales y planes de carrera.

- **Diseño de programas de formación:** Si la educación es el factor más correlacionado con prestigio y valoración, invertir en certificaciones, posgrados o especializaciones técnicas tiene respaldo empírico.
- **Análisis de equidad:** La correlación negativa de Women con Prestige puede alertar a la empresa sobre posibles brechas de valoración entre roles ocupados mayoritariamente por mujeres, orientando políticas de equidad salarial.

**¿Qué grupos de ocupaciones se identificaron?**

Con K=4 se identificaron cuatro perfiles diferenciados:

- **Clúster de alta especialización:** Educación alta, ingresos altos, prestigio alto. Equivalente a roles senior técnicos o gerenciales en una empresa de software.
- **Clúster intermedio-alto:** Educación media-alta, ingresos moderados. Perfiles junior o analistas con formación universitaria.
- **Clúster intermedio-bajo:** Educación media, ingresos bajos. Soporte técnico, operadores, roles de servicios.
- **Clúster de baja especialización:** Educación baja, ingresos bajos, prestigio bajo. Oficios manuales o de servicios básicos, poco representados en el sector software.

**¿Existen resultados anómalos o difíciles de explicar?**

Sí. Algunas ocupaciones presentan ingresos relativamente altos, pero prestigio moderado, o viceversa. Esto puede deberse a que el dataset fue construido en un contexto histórico y geográfico específico, por lo que ciertos valores de prestigio no reflejan necesariamente la valoración actual del mercado de tecnología.

**¿Qué información adicional haría falta para mejores decisiones?**

- Datos actualizados del mercado laboral tecnológico (2020–2025).
- Variables específicas del sector: stack tecnológico, años de experiencia, modalidad de trabajo (remoto/presencial).
- Indicadores de desempeño organizacional vinculados a los perfiles.

## Conclusión

El análisis realizado sobre el dataset Prestige_modificado permite extraer tres conclusiones principales con aplicación directa para InnovaSoft Analytics:

1. **La educación es el factor más asociado al prestigio ocupacional.** Para una empresa de software, esto respalda la inversión en formación técnica continua como estrategia para elevar la valoración y retención del talento.
2. **Los perfiles ocupacionales se agrupan en cuatro segmentos claramente diferenciados.** Estos grupos pueden usarse como marco de referencia para diseñar estructuras de roles, niveles de seniority y bandas salariales dentro de la organización.
3. **Existen patrones de valoración que merecen revisión desde una perspectiva de equidad.** La relación negativa entre participación femenina y prestigio debe ser considerada al momento de definir políticas de compensación y reconocimiento.

Este flujo de trabajo, carga, inspección, correlación, visualización, agrupación e interpretación es replicable y automatizable, lo que lo convierte en una herramienta válida dentro de un proceso de producción industrial de software basado en datos.

# Anexos

Link a GitHub: [dataminingDavidChavez25-3453-2021/ActividadU4Selectiva2 at main · dechl-98/dataminingDavidChavez25-3453-2021]

```python
#creamos variables para mandar a traer el dataset
url = "https://raw.githubusercontent.com/dechl-98/dataminingDavidChavez25-3453-2021/refs/heads/main/ActividadU4Selectiva2/Prestige_modificado.csv"
df = pd.read_csv(url, sep=';') #agregamos una separación por ; para poder manejar los encabezados de las tablas
df.head()
```

| | occupation | education | income | women | prestige | census | type_num |
|---|---|---|---|---|---|---|---|
| 0 | gov.administrators | 13.11 | 12351 | 11.16 | 68.8 | 1113 | 1 |
| 1 | general.managers | 12.26 | 25879 | 4.02 | 69.1 | 1130 | 1 |
| 2 | accountants | 12.77 | 9271 | 15.70 | 63.4 | 1171 | 1 |
| 3 | purchasing.officers | 11.42 | 8865 | 9.11 | 56.8 | 1175 | 1 |
| 4 | chemists | 14.62 | 8403 | 11.68 | 73.5 | 2111 | 1 |

```python
#verificamos la información general del dataset
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 102 entries, 0 to 101
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   occupation  102 non-null    object
 1   education   102 non-null    float64
 2   income      102 non-null    int64
 3   women       102 non-null    float64
 4   prestige    102 non-null    float64
 5   census      102 non-null    int64
 6   type_num    102 non-null    int64
dtypes: float64(3), int64(3), object(1)
memory usage: 5.7+ KB
```

```python
# verificamos valores nulos por columna y los registros que podrían ser duplicados
print("Valores nulos por columna:")
print(df.isnull().sum())

# Registros duplicados
print("\nCantidad de registros duplicados:", df.duplicated().sum())
```

```
Valores nulos por columna:
occupation    0
education     0
income        0
women         0
prestige      0
census        0
type_num      0
dtype: int64

Cantidad de registros duplicados: 0
```

```python
# Generamos la estadística descriptitva de las diferentes variables numericas
df.describe()
```

| | education | income | women | prestige | census | type_num |
|---|---|---|---|---|---|---|
| count | 102.000000 | 102.000000 | 102.000000 | 102.000000 | 102.000000 | 102.000000 |
| mean | 10.738039 | 6797.901961 | 28.979020 | 46.833333 | 5401.774510 | 1.843137 |
| std | 2.728444 | 4245.922227 | 31.724931 | 17.204486 | 2644.993215 | 0.817447 |
| min | 6.380000 | 611.000000 | 0.000000 | 14.800000 | 1113.000000 | 0.000000 |
| 25% | 8.445000 | 4106.000000 | 3.592500 | 35.225000 | 3120.500000 | 1.000000 |
| 50% | 10.540000 | 5930.500000 | 13.600000 | 43.600000 | 5135.000000 | 2.000000 |
| 75% | 12.647500 | 8187.250000 | 52.202500 | 59.275000 | 8312.500000 | 2.000000 |
| max | 15.970000 | 25879.000000 | 97.510000 | 87.200000 | 9517.000000 | 3.000000 |

```python
#Calculamos la matris de correlación de las variables numéricas.
# Selección de variables numéricas
variables_numericas = df.select_dtypes(include=['int64', 'float64'])
# Matriz de correlación completa
matriz_correlacion = variables_numericas.corr()
print("Matriz de correlación completa (redondeada a 3 decimales):")
display(matriz_correlacion.round(3))
print(matriz_correlacion['prestige'].sort_values(ascending=False).round(3))
```

```
Matriz de correlación completa (redondeada a 3 decimales):
```

| | education | income | women | prestige | census | type_num |
|---|---|---|---|---|---|---|
| education | 1.000 | 0.578 | 0.062 | 0.850 | -0.823 | -0.382 |
| income | 0.578 | 1.000 | -0.441 | 0.715 | -0.361 | -0.368 |
| women | 0.062 | -0.441 | 1.000 | -0.118 | -0.227 | 0.251 |
| prestige | 0.850 | 0.715 | -0.118 | 1.000 | -0.635 | -0.465 |
| census | -0.823 | -0.361 | -0.227 | -0.635 | 1.000 | 0.288 |
| type_num | -0.382 | -0.368 | 0.251 | -0.465 | 0.288 | 1.000 |

```
prestige     1.000
education    0.850
income       0.715
women       -0.118
type_num    -0.465
census      -0.635
Name: prestige, dtype: float64
```

```python
#Gráfica de dispersión entre prestige y education.
plt.figure(figsize=(8, 5))
plt.scatter(df['education'], df['prestige'], color='steelblue', alpha=0.75, edgecolors='white', s=60)
plt.xlabel('education (nivel educativo promedio)', fontsize=11)
plt.ylabel('prestige (prestigio ocupacional)', fontsize=11)
plt.title('Relación entre Educación y Prestigio', fontsize=13, fontweight='bold')
plt.grid(linestyle='--', alpha=0.4)
plt.tight_layout()
plt.show()
```

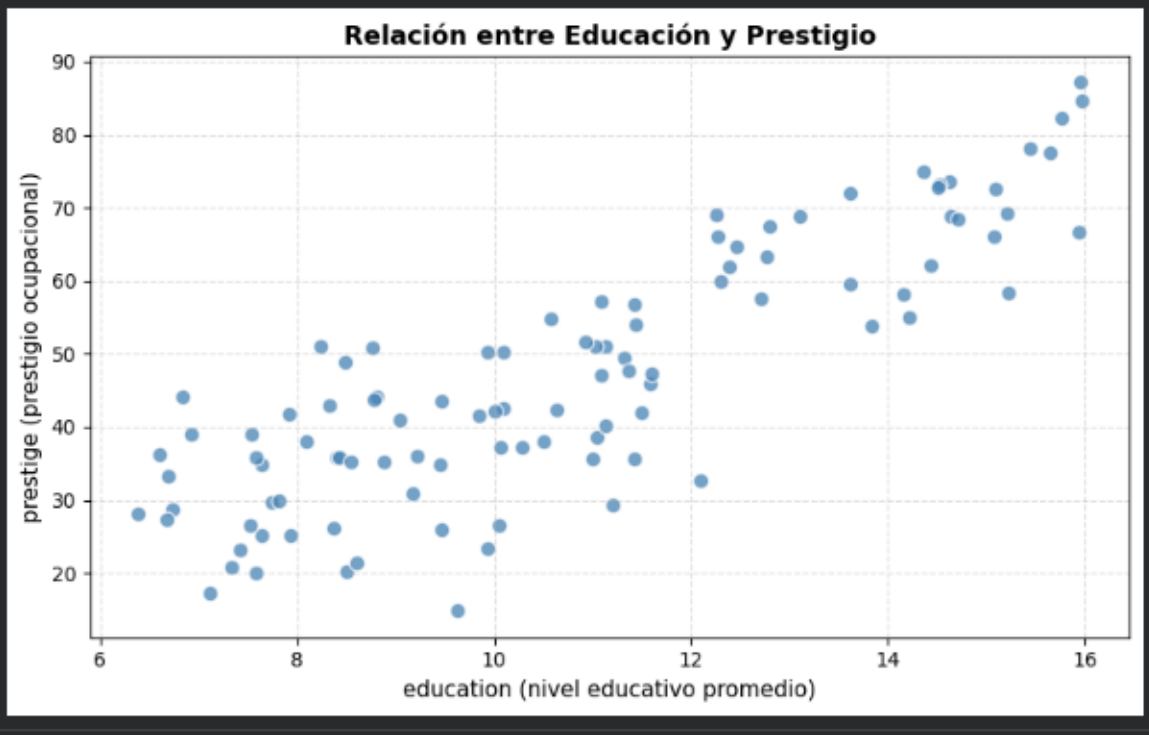

```python
#Gráfica de dispersión entre Prestige e Income
plt.figure(figsize=(8, 5))
plt.scatter(df['income'], df['prestige'], color='darkorange', alpha=0.75, edgecolors='white', s=60)
plt.xlabel('income (ingreso promedio)', fontsize=11)
plt.ylabel('prestige (prestigio ocupacional)', fontsize=11)
plt.title('Relación entre Ingreso y Prestigio', fontsize=13, fontweight='bold')
plt.grid(linestyle='--', alpha=0.4)
plt.tight_layout()
plt.show()
```

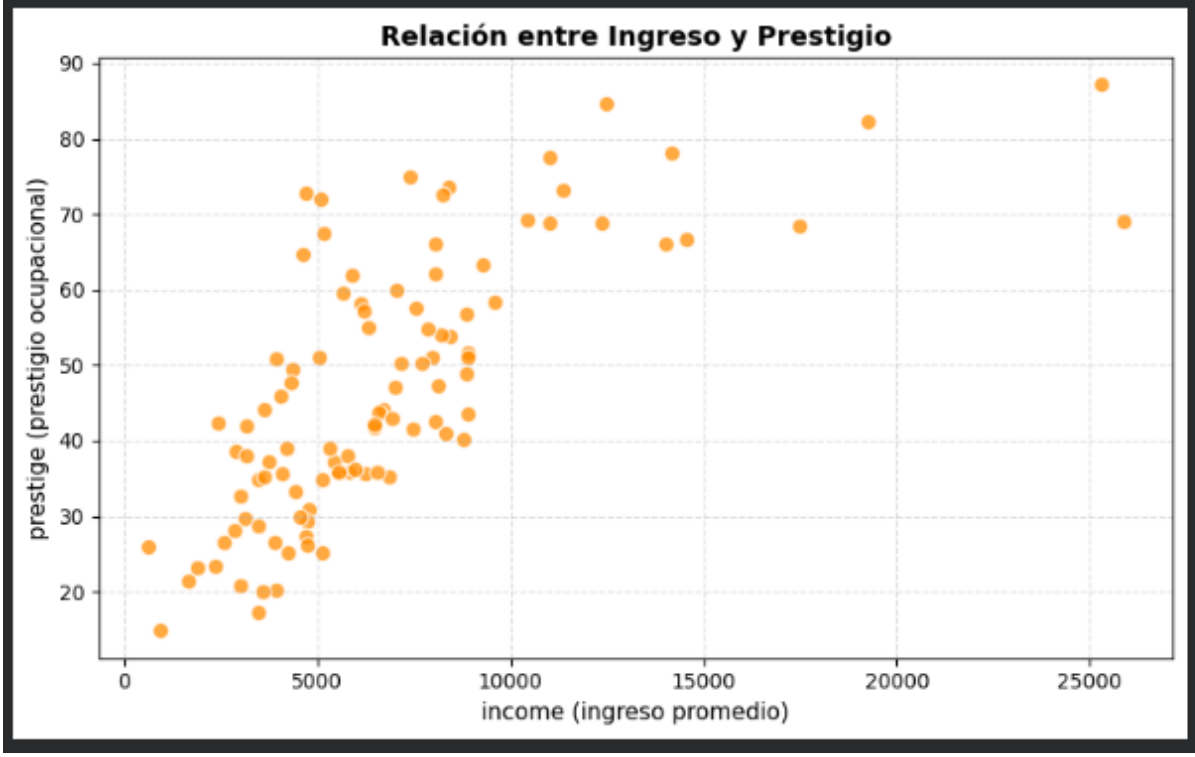

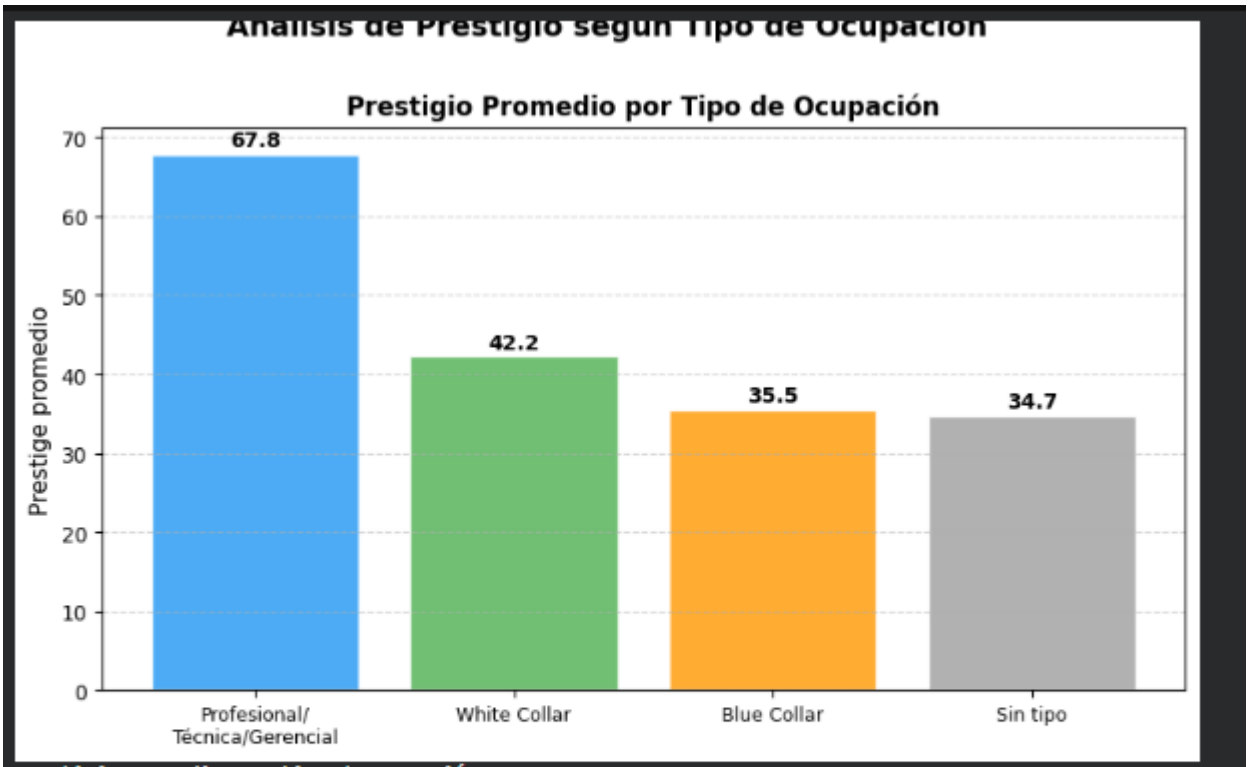


Prestigio promedio por tipo de ocupación:

| Type_label | mean | median | std | count |
|---|---|---|---|---|
| Blue Collar | 35.53 | 35.9 | 10.02 | 44 |
| Profesional/\nTécnica/Gerencial | 67.85 | 68.4 | 8.68 | 31 |
| Sin tipo | 34.72 | 35.0 | 17.68 | 4 |
| White Collar | 42.24 | 41.5 | 9.52 | 23 |

```python
#Actividad 4. Análisis de agrupación de ocupaciones (K-Means)
# Selección de variables para clusterización
columnas_cluster = ['education', 'income', 'women', 'prestige', 'type_num']
X = df[columnas_cluster].copy()

# Escalamiento de datos — obligatorio antes de K-Means
escalador = StandardScaler()
X_escalado = escalador.fit_transform(X)
print("Variables seleccionadas para clusterización:", columnas_cluster)
print("Datos escalados (primeras 5 filas):")
print(pd.DataFrame(X_escalado, columns=columnas_cluster).head().round(3))
```

```
Variables seleccionadas para clusterización: ['education', 'income', 'women', 'prestige', 'type_num']
Datos escalados (primeras 5 filas):
   education  income  women  prestige  type_num
0      0.874   1.314 -0.564     1.283    -1.037
1      0.561   4.516 -0.791     1.301    -1.037
2      0.748   0.585 -0.421     0.968    -1.037
3      0.251   0.489 -0.629     0.582    -1.037
4      1.430   0.380 -0.548     1.558    -1.037
```

```python
# K-Means con cuatro clústers
modelo_k4 = KMeans(n_clusters=4, random_state=42, n_init=10)
df['Cluster_4'] = modelo_k4.fit_predict(X_escalado)

print("=== Centroides del modelo K=4 (valores originales promedio) ===")
centroides_k4 = df.groupby('Cluster_4')[columnas_cluster].mean().round(2)
centroides_k4['n_ocupaciones'] = df.groupby('Cluster_4').size()
display(centroides_k4)
```

```
=== Centroides del modelo K=4 (valores originales promedio) ===
```

| Cluster_4 | education | income | women | prestige | type_num | n_ocupaciones |
|---|---|---|---|---|---|---|
| 0 | 13.59 | 7329.35 | 36.35 | 63.33 | 0.95 | 20 |
| 1 | 8.82 | 5878.74 | 9.60 | 37.26 | 2.09 | 47 |
| 2 | 10.12 | 3545.04 | 74.16 | 37.76 | 2.57 | 23 |
| 3 | 14.69 | 15746.83 | 6.00 | 74.23 | 1.00 | 12 |

```python
# K-Means con cinco clúster
modelo_k5 = KMeans(n_clusters=5, random_state=42, n_init=10)
df['Cluster_5'] = modelo_k5.fit_predict(X_escalado)

print("=== Centroides del modelo K=5 (valores originales promedio) ===")
centroides_k5 = df.groupby('Cluster_5')[columnas_cluster].mean().round(2)
centroides_k5['n_ocupaciones'] = df.groupby('Cluster_5').size()
display(centroides_k5)
```

```
=== Centroides del modelo K=5 (valores originales promedio) ===
```

| Cluster_5 | education | income | women | prestige | type_num | n_ocupaciones |
|---|---|---|---|---|---|---|
| 0 | 10.94 | 3909.12 | 73.76 | 41.50 | 2.88 | 17 |
| 1 | 9.31 | 6922.03 | 5.84 | 42.18 | 2.25 | 32 |
| 2 | 13.59 | 7329.35 | 36.35 | 63.33 | 0.95 | 20 |
| 3 | 7.78 | 3327.48 | 34.10 | 26.87 | 1.71 | 21 |
| 4 | 14.69 | 15746.83 | 6.00 | 74.23 | 1.00 | 12 |

```
plt.show()
```

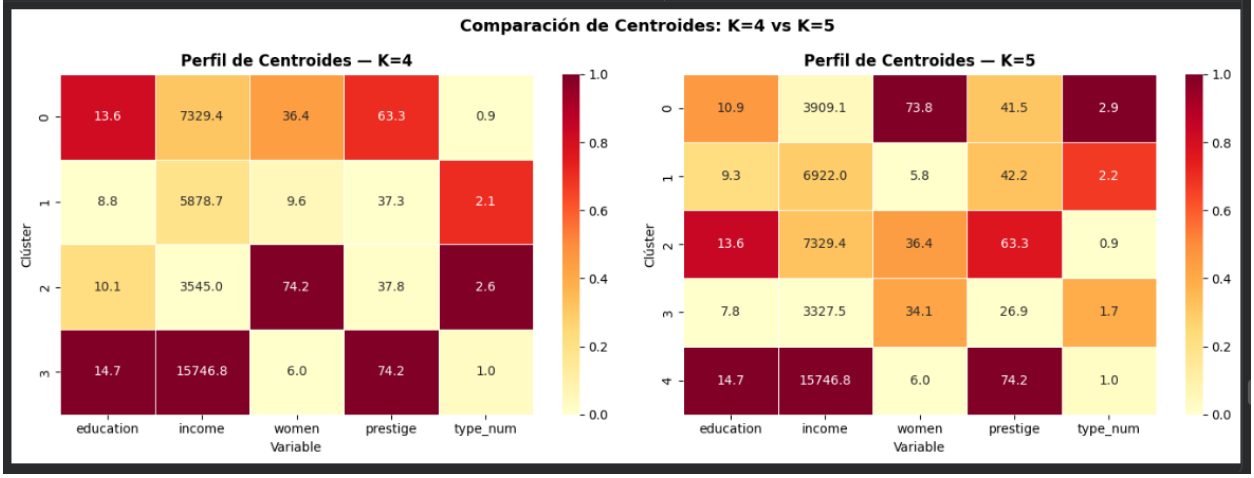


```
print(df.groupby('Cluster_5')[columnas_cluster].mean().round(2))
```

```
           education    income  women  prestige  type_num
Cluster_4
0              13.59   7329.35  36.35     63.33      0.95
1               8.82   5878.74   9.60     37.26      2.09
2              10.12   3545.04  74.16     37.76      2.57
3              14.69  15746.83   6.00     74.23      1.00
           education    income  women  prestige  type_num
Cluster_5
0              10.94   3909.12  73.76     41.50      2.88
1               9.31   6922.03   5.84     42.18      2.25
2              13.59   7329.35  36.35     63.33      0.95
3               7.78   3327.48  34.10     26.87      1.71
4              14.69  15746.83   6.00     74.23      1.00
```